

$$\min_{x \in \mathbb{R}^d} f(x)$$

L - Lipschitz, μ - сильная выпуклость

$$O\left(\frac{L}{\mu} \log \frac{\|x^0 - x^*\|_2}{\varepsilon}\right) \text{ итераций / градиентных вычислений}$$

функции градиентному спуску

а можно лучше?

1964. Б.П. Ткачук



Алгоритм 1 Метод тяжелого шарика

Вход: размер шагов $\{\gamma_k\}_{k=0} > 0$, моменты $\{\tau_k\}_{k=0} \in [0; 1]$, стартовая точка $x^0 = x^{-1} \in \mathbb{R}^d$, количество итераций K

- 1: for $k = 0, 1, \dots, K-1$ do
- 2: Вычислить $\nabla f(x^k)$
- 3: $x^{k+1} = x^k - \gamma_k \nabla f(x^k) + \tau_k (x^k - x^{k-1})$
- 4: end for

Выход: x^K

Физический смысл:



Pytorch (основан на Submanifold DL)

$$\begin{cases} V^{k+1} = \beta V^k + \nabla f(x^k) \\ x^{k+1} = x^k - \gamma V^{k+1} \end{cases} \quad \beta \in [0; 1]$$

GD с моментом

$$x^{k+1} = x^k - \gamma \nabla f(x^k) - \gamma \beta v^k \leftarrow$$

$$x^k = x^{k-1} - \gamma v^k \Rightarrow \gamma v^k = x^{k-1} - x^k$$

$$x^{k+1} = x^k - \gamma \nabla f(x^k) + \beta (x^k - x^{k-1})$$

⊕:

- + интуиция и физика
- + легкость интерпретации
- + геометрические вычисления

⊖:

- два параметра для подбора ($\tau \in [0.85; 0.95]$)
- во памяти +1 вектор по сравнению с град. спуска
- в теории не лучше град. спуска

1983 Ю.Е. Касперов

Алгоритм 3 Ускоренный градиентный метод

Вход: размер шагов $\{\gamma_k\}_{k=0} > 0$, моменты $\{\tau_k\}_{k=0} \in [0; 1]$,
стартовая точка $x^0 = y^0 \in \mathbb{R}^d$, количество итераций K

- 1: for $k = 0, 1, \dots, K-1$ do
- 2: Вычислить $\nabla f(y^k)$
- 3: $x^{k+1} = y^k - \gamma_k \nabla f(y^k)$
- 4: $y^{k+1} = x^{k+1} + \tau_k (x^{k+1} - x^k)$
- 5: end for

Выход: x^K

Пятилетний шаг:

$$x^{k+1} = x^k - \gamma \nabla f(x^k) + \tau (x^k - x^{k-1})$$

Ускоренный шаг:

$$y^k = x^k + \tau (x^k - x^{k-1})$$

$$x^{k+1} = y^k - \gamma_k \nabla f(y^k)$$

$$x^{k+1} = x^k + \underbrace{\tau (x^k - x^{k-1})}_{m.m.} - \gamma_k \nabla f(x^k + \tau (x^k - x^{k-1}))$$

Другой метод, использующий градиентный спуск

Алгоритм 4 Линейный каплинг: внутренний цикл

Вход: размер шагов $\{\gamma_k\}_{k=0} > 0$ и $\{\eta_k\}_{k=0} > 0$, моменты $\{\tau_k\}_{k=0} \in [0, 1]$, стартовая точка $x^0 = y^0 = z^0 \in \mathbb{R}^d$, количество итераций K

1: for $k = 0, 1, \dots, K-1$ do

2: Вычислить $\nabla f(x^k)$

3: $y^{k+1} = x^k - \eta_k \nabla f(x^k)$ \leftarrow *стандартный шаг*

4: $z^{k+1} = z^k - \gamma_k \nabla f(x^k)$ \leftarrow *дискретный шаг*

5: $x^{k+1} = \tau_k z^{k+1} + (1 - \tau_k) y^{k+1}$ \leftarrow *всм. комб.*

6: end for

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} x^k$

$$\frac{1-\tau}{\tau} = \frac{\delta}{\eta(2-L\eta)} \leftarrow \text{выбираем } \tau$$

$$\eta = \frac{1}{L} \quad \delta = \frac{1}{\sqrt{\mu L}}$$

$$f\left(\frac{1}{K} \sum_{k=1}^K x^k\right) - f^* \leq \sqrt{\frac{4L}{\mu K^2}} (f(x^0) - f^*)$$

$$\Rightarrow \frac{1}{2}$$

$$K = 4 \sqrt{\frac{L}{\mu}}$$

$$f\left(\frac{1}{K} \sum_{k=1}^K x^k\right) - f^* \leq \frac{1}{2} (f(x^0) - f^*)$$

\uparrow
Результат из новой стартовой точки

$$f(x_{\text{final, new}}) - f^* \leq \frac{1}{2} (f(x_{\text{start, new}}) - f^*)$$

//

Тогда нужно $\log_2 \frac{f(x^0) - f^*}{\varepsilon}$ x_{final} повторений,

чтобы гарантированно получить

ε по среднему $f(x) - f^* \leq \varepsilon$

Общая сложность: $\frac{4 \sqrt{L}}{\mu} \log_2 \frac{f(x^0) - f^*}{\varepsilon}$

K

О сходимости линейного каплинга

Пусть задача безусловной оптимизации с L -гладкой, μ -сильно выпуклой целевой функцией f решается с помощью реставрированного линейного каплинга. Тогда при $\eta = \frac{1}{L}$, $\gamma = \sqrt{\frac{1}{\mu L}}$ и $K = \sqrt{\frac{16L}{\mu}}$, чтобы добиться точности ε по функции ($f(x) - f(x^*) \leq \varepsilon$), необходимо

Ускор. $\rightarrow O\left(\sqrt{\frac{L}{\mu}} \log \frac{f(x^0) - f(x^*)}{\varepsilon}\right)$ вызовов оракула.

улучш. метри. оценки

лучше чем граф сужск $\frac{L}{\mu} \log \dots$


сходимость по функции:

- где сильно выпуклая задача \approx эквивалентно
- где ускор. метода Касперова

сходимости:

$$\|x^k - x^*\|_2^2 + f(x^k) - f^*$$

Можно ли еще лучше? Миним. оценка



Класс методов:

- $x^0 = 0$ стартовая точка

$$\mathcal{M}_0 = \{x^0\} \leftarrow \text{послед. память}$$

- $\nabla f(x^k)$ $x^k \in \mathcal{M}_k$

- $\mathcal{M}_{k+1} = \text{span} \{ \mathcal{M}_k, \nabla f(x^k) \} \leftarrow \text{мин. оболочка}$

- K вызовов оракула $x_{\text{final}} \in \mathcal{M}_K$

Примеры

$$f(x) = \frac{L-\mu}{8} x^T A x + \frac{\mu}{2} \|x\|_2^2 - \frac{L-\mu}{4} e_1^T x$$

$$A = \begin{pmatrix} 2 & -1 & & 0 \\ -1 & 2 & & \\ & & \ddots & \\ 0 & & & -1 & 2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \end{pmatrix} e_1 = \begin{pmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix}$$

1) f - L -выпуклая, μ -сильно выпуклая

$$\|A\|_2 \leq 4 \quad A \neq 0 \quad \text{симметричная}$$

2) x^* - решение задачи

$$\nabla f(x^*) = 0$$

$$\frac{L-\mu}{8} \cdot 2Ax + \frac{\mu}{2} \cdot 2x - \frac{L-\mu}{4} e_1 = 0$$

но-координаты:

$$1. \frac{L-\mu}{4} (2x_1 - x_2) + \mu x_1 - \frac{L-\mu}{4} = 0$$

гипотеза $\frac{L-\mu}{4} (-x_{k-1} + 2x_k - x_{k+1}) + \mu x_k = 0$

поэтому: ...

$$x_{k+1} = \left(2 + \frac{4\mu}{L-\mu} \right) x_k - x_{k-1}$$

используем характеристическое уравнение

$$\lambda^2 = \left(2 + \frac{4\mu}{L-\mu} \right) \lambda - 1$$

$$\lambda_{\text{реальное}} : \lambda_1 = \frac{\sqrt{L-\mu}}{\sqrt{L+\mu}} \quad \lambda_2 = \dots$$

$$X_k = C_1 \lambda_1^k + C_2 \lambda_2^k$$

зададим нач. условием $C_2 = 0$ $C_1 = 1$

$$X_k = \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^k$$

$$3) \nabla f(x) = \frac{L-\mu}{8} \cdot 2Ax + \frac{\mu}{2} \cdot 2x - \frac{L-\mu}{4} e_1$$

1. $x^0 = 0$ $\nabla f(x^0) \in \text{span}\{e_1\}$
первый шаг не нужен

$$\mathcal{M}_1 \subseteq \text{span}\{e_1\}$$

2. $x^1 \in \mathcal{M}_1$ $\nabla f(x^1) \in \text{span}\{e_1, e_2\}$
первый и второй шаги нужны

$$\mathcal{M}_2 \subseteq \text{span}\{e_1, e_2\}$$

k. $x^{k-1} \in \mathcal{M}_{k-1}$ $\nabla f(x^{k-1}) \in \text{span}\{e_1, \dots, e_k\}$

Summary:

$$X_k^* = \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^k = q^k$$

нам \bar{I} точек требуется найти \bar{I} точек
нужно

$$\|X_{\text{final}}^{\bar{I}} - X^*\|^2 = \sum_{i=1}^d (X_{\text{find}, i}^{\bar{I}} - X_i^*)^2$$

$d = 2\bar{I}$ точек не все нужны.

в нашем случае можно задать \bar{I} точек,
где 0

$$\geq \sum_{i=\bar{K}+1}^{2\bar{K}=d} (x_{\text{final},i}^{\bar{K}} - x_i^*)^2$$

$$\|x_{\text{final}}^{\bar{K}} - x^*\|^2 = \sum_{i=\bar{K}+1}^{2\bar{K}} (x_i^*)^2 = \sum_{i=\bar{K}+1}^{2\bar{K}} q^{2i}$$

$$\|x^0 - x^*\|_2^2 = \sum_{i=1}^{2\bar{K}} (x_i^*)^2 = \sum_{i=1}^{2\bar{K}} q^{2i}$$

$$\sum_{i=1}^{2\bar{K}} q^{2i} = \sum_{i=1}^{\bar{K}} q^{2i} + \sum_{i=\bar{K}+1}^{2\bar{K}} q^{2i} = (1 + q^{2\bar{K}}) \sum_{i=1}^{\bar{K}} q^{2i}$$

$$q^{2\bar{K}} \sum_{i=1}^{\bar{K}} q^{2i}$$

$$\sum_{i=\bar{K}+1}^{2\bar{K}} q^{2i} = q^{2\bar{K}} \sum_{i=1}^{\bar{K}} q^{2i}$$

$$\|x_{\text{final}}^{\bar{K}} - x^*\|_2^2 \geq \frac{q^{2\bar{K}}}{1 + q^{2\bar{K}}} \|x^0 - x^*\|_2^2$$

$$\geq \frac{q^{2\bar{K}}}{1 + 1} \|x^0 - x^*\|_2^2 \sim \left(1 - \sqrt{\frac{\mu}{L}}\right)^K \frac{\|x^0 - x^*\|_2^2}{2}$$

K через ε

$$K \sim \sqrt{\frac{L}{\mu}} \log \dots$$

Нижняя оценка на оракульную сложность

Для любого метода из класса, описанного выше, существует безусловная задача оптимизации с L -гладкой, μ -сильно выпуклой целевой функцией f такая, что для решения этой задачи методу необходимо

необходимо

минимальная
оптимальность
существование
методов

$$\Omega\left(\sqrt{\frac{L}{\mu}} \log \frac{\|x^0 - x^*\|_2}{\varepsilon}\right) \text{ вызовов оракула.}$$