

$$\min_{x \in \mathbb{R}^d} f(x)$$

A simple hand-drawn smiley face consisting of two vertical lines for eyes and a curved line for a mouth.

$$\min_{x \in \mathbb{R}^d} f(x) := \mathbb{E}_{f \sim D} [f(x, f)]$$

Turner:

problem:

$\min_{x \in \mathbb{R}^d} \mathbb{E}_{\xi \sim \mathcal{D}} [\mathcal{L}(g(x, \xi_a), \xi_b)]$ (1)

Annotations:

- $\xi \sim \mathcal{D}$: ξ_a, ξ_b
- \mathcal{L} : loss
- g : generator
- ξ_a : noise
- ξ_b : real image
- \mathbb{E} : expectation
- \mathbb{R}^d : parameter space

Можно считать, что $\mathbb{R}^f(x)$, а $\mathbb{R}_x^f(x, f)$

Түргөткөнүмүз:

$$E_x [\nabla f(x, \xi)] = \nabla f(x)$$

Итак, мы имеем zero с ограниченными переменными:

$$\min_{x \in \mathbb{R}^d} \left[\frac{1}{n} \sum_{i=1}^n \ell(g(x, f_a^i), f_b^i) \right] \quad (2)$$

у нас есть и обзорное
с углем. комбинация

(2) Момент - Криво изгибающегося (1)

где (2) означает $\nabla f(x)$, но не хочу

- дорого
- добавит сложности/колебаний где надо, чтобы быть ближе к (1)

Поэтому будем использовать $\nabla f(x, \xi^i)$

Если i выбрано равномерно, то

$$\begin{aligned} \mathbb{E}_i [\nabla f(x, \xi^i)] &= \sum_{j=1}^n \mathbb{P}\{\xi^i = j\} \nabla f(x, \xi^j) \\ &= \frac{1}{n} \sum_{j=1}^n \nabla_x [L(g(x, \xi_a^j), \xi_b^j)] \\ &= \nabla_x \left[\frac{1}{n} \sum_{j=1}^n L(g(x, \xi_a^j), \xi_b^j) \right] \\ &= \nabla f(x) \end{aligned}$$

Метод стох. градиента

Алгоритм 1 Стохастический градиентный спуск (SGD)

Вход: размеры шагов $\{\gamma_k\}_{k=0} > 0$, стартовая точка $x^0 \in \mathbb{R}^d$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K-1$ **do**
- 2: Сгенерировать **независимо** ξ^k
- 3: Вычислить стохастический градиент $\nabla f(x^k, \xi^k)$
- 4: $x^{k+1} = x^k - \gamma_k \nabla f(x^k, \xi^k)$
- 5: **end for**

Выход: x^K

← элемент $\nabla f(x)$

Свойства

$$\mathbb{E}[\cdot | x^k] = \mathbb{E}[\cdot | \mathcal{F}_k]$$

\mathcal{F}_k - σ алгебра, задан. сугр. $X^0, \xi^0, \xi^1, \dots, \xi^{k-1}$

Сугр - "grouping" всего случайных го
мезуров унепану

tower property

$$E[X] = E[E[X|Y]]$$

Dok. to assumption:

- f - L -нагрун, μ -сугр-сугр-сугр
- предположение на случайности

$$E_{\xi} [\nabla f(x, \xi)] = \nabla f(x)$$

$$E_{\xi} [\|\nabla f(x, \xi) - \nabla f(x)\|_2^2] \leq \sigma^2$$

Dok. to:

$$\begin{aligned} \|x^{k+1} - x^*\|_2^2 &= \|x^k - \gamma \nabla f(x^k, \xi^k) - x^*\|_2^2 \\ &= \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k, \xi^k), x^k - x^* \rangle \\ &\quad + \gamma^2 \|\nabla f(x^k, \xi^k)\|_2^2 \end{aligned}$$

$$E[\cdot | x^k]$$

здесь не с.б. конн $E[\cdot | x^k]$

$$\begin{aligned} E[\|x^{k+1} - x^*\|_2^2 | x^k] &= E[\|x^k - x^*\|_2^2 | x^k] \\ &\quad - 2\gamma E[\langle \nabla f(x^k, \xi^k), x^k - x^* \rangle | x^k] \\ &\quad + \gamma^2 E[\|\nabla f(x^k, \xi^k)\|_2^2 | x^k] \end{aligned}$$

$$\mathbb{E}[\langle \nabla f(x^k, \xi^k); x^k - x^* \rangle | x^k]$$

$$= \langle \mathbb{E}[\nabla f(x^k, \xi^k) | x^k]; x^k - x^* \rangle \quad (\text{no dependence on } \xi^k)$$

$$= \langle \nabla f(x^k); x^k - x^* \rangle \quad (\text{indep. } \xi^k)$$

$$\mathbb{E}[\|x^{k+1} - x^*\|_2^2 | x^k] = \|x^k - x^*\|_2^2 \quad (+)$$

$$- 2\gamma \langle \nabla f(x^k); x^k - x^* \rangle \quad (+)$$

$$+ \gamma^2 \mathbb{E}[\|\nabla f(x^k, \xi^k)\|_2^2 | x^k]$$

$$\mathbb{E}[\|\nabla f(x^k, \xi^k)\|_2^2 | x^k] =$$

$$\mathbb{E}[\|\nabla f(x^k, \xi^k) - \nabla f(x^k)\|_2^2 + \|\nabla f(x^k)\|_2^2 - 2\langle \nabla f(x^k); \nabla f(x^k, \xi^k) - \nabla f(x^k) \rangle | x^k] \quad \circ$$

$$= \mathbb{E}[\|\nabla f(x^k, \xi^k) - \nabla f(x^k)\|_2^2 + \|\nabla f(x^k)\|_2^2 | x^k]$$

$$= \mathbb{E}[\|\nabla f(x^k, \xi^k) - \nabla f(x^k)\|_2^2 | x^k] + \|\nabla f(x^k)\|_2^2$$

$$\leq \sigma^2 + \|\nabla f(x^k)\|_2^2$$

(no 2 independent)

$$\mathbb{E}[\|x^{k+1} - x^*\|_2^2 | x^k] \leq \|x^k - x^*\|_2^2 \quad (+)$$

$$- 2\gamma \langle \nabla f(x^k); x^k - x^* \rangle \quad (+)$$

$$+ \gamma^2 \|\nabla f(x^k)\|_2^2 + \gamma^2 \sigma^2 \quad (+)$$

μ -сильно вып. L -гладкая

$$\begin{aligned}
 &\leq \|x^k - x^*\|_2^2 \\
 &\quad - \mu\gamma \|x^k - x^*\|_2^2 - 2\gamma(f(x^k) - f(x^*)) \\
 &\quad + \gamma^2 \cdot 2L(f(x^k) - f(x^*)) + \gamma^2 \sigma^2 \\
 &= (1 - \gamma\mu) \|x^k - x^*\|_2^2 \\
 &\quad - \gamma(1 - \gamma L)(f(x^k) - f(x^*)) \\
 &\quad + \gamma^2 \sigma^2
 \end{aligned}$$

$$\gamma \leq \frac{1}{L}$$

$$\mathbb{E}[\|x^{k+1} - x^*\|_2^2 \mid x^k] \leq (1 - \gamma\mu) \|x^k - x^*\|_2^2 + \gamma^2 \sigma^2$$

\mathbb{E} надежда $\mathbb{E}[x] = \mathbb{E}[\mathbb{E}[x|Y]]$

$$\mathbb{E}[\|x^{k+1} - x^*\|_2^2] \leq (1 - \gamma\mu) \mathbb{E}[\|x^k - x^*\|_2^2] + \gamma^2 \sigma^2$$

Теорема сходимости SGD в случае ограниченной дисперсии

Пусть задача безусловной стохастической оптимизации с L -гладкой, μ -сильно выпуклой целевой функцией f решается с помощью SGD с $\gamma_k \leq \frac{1}{L}$ в условиях несмещенности и ограниченности дисперсии стохастического градиента. Тогда справедлива следующая оценка сходимости

$$\mathbb{E}[\|x^{k+1} - x^*\|^2] \leq (1 - \gamma_k \mu) \mathbb{E}[\|x^k - x^*\|^2] + \gamma_k^2 \sigma^2.$$

Замыслим рекуррентно


$$\begin{aligned} \mathbb{E}[\|x^{k+1} - x^*\|_2^2] &\leq (1-\gamma\mu) \mathbb{E}[\|x^k - x^*\|_2^2] + \gamma^2 \sigma^2 \\ &\leq (1-\gamma\mu)(1-\gamma\mu) \mathbb{E}[\|x^{k-1} - x^*\|_2^2] + \gamma^2 \sigma^2 + \gamma^2 \sigma^2 \\ &\leq (1-\gamma\mu)^2 \mathbb{E}[\|x^{k-1} - x^*\|_2^2] \\ &\quad + \gamma^2 \sigma^2 + (1-\gamma\mu) \gamma^2 \sigma^2 \end{aligned}$$

$$\begin{aligned} &\dots \\ &\leq (1-\gamma\mu)^{k+1} \mathbb{E}[\|x^0 - x^*\|_2^2] \\ &\quad + \gamma^2 \sigma^2 \sum_{i=0}^k (1-\gamma\mu)^i \end{aligned}$$

$$\leq \sum_{i=0}^{\infty} (1-\gamma\mu)^i = \frac{1}{\gamma\mu}$$

$$\mathbb{E}[\|x^{k+1} - x^*\|_2^2] \leq \underbrace{(1-\gamma\mu)^{k+1} \mathbb{E}[\|x^0 - x^*\|_2^2]}_{\text{ограничено}} + \underbrace{\frac{\gamma^2 \sigma^2}{\gamma\mu}}_{\text{ограничено}}$$


характерная сходимость:




индексная
сходимость
к пределу

Борелов за ограниченность:

- решение метода с неограниченным шагом



- $\gamma_k = \frac{1}{k+1} ; \quad \frac{1}{\sqrt{k+1}}$



- $\text{we want, we } \sigma^2$

$$\nabla f(x^k, \xi^k) \rightarrow \frac{1}{b} \sum_{\xi \in S^k} \nabla f(x^k, \xi)$$

$|S^k| = b$
 Summe, wobei ξ random aus f

$$\mathbb{E} \left[\left\| \frac{1}{b} \sum_{\xi \in S^k} \nabla f(x^k, \xi) - \nabla f(x^k) \right\|_2^2 \middle| x^k \right] \leq \frac{\sigma^2}{b}$$

$$\mathbb{E} \left[\left\| \frac{1}{b} \sum_{\xi \in S^k} \nabla f(x^k, \xi) - \nabla f(x^k) \right\|_2^2 \middle| x^k \right] =$$

$$= \mathbb{E} \left[\frac{1}{b^2} \sum_{\xi \in S^k} \underbrace{\left\| \nabla f(x^k, \xi) - \nabla f(x^k) \right\|_2^2}_{\leq \sigma^2} \middle| x^k \right]$$

$$+ \mathbb{E} \left[\frac{1}{b^2} \sum_{\substack{\xi, \eta \in S^k \\ \xi \neq \eta}} \langle \nabla f(x^k, \xi) - \nabla f(x^k), \nabla f(x^k, \eta) - \nabla f(x^k) \rangle \middle| x^k \right]$$

① $(\xi, \eta - \text{negativ})$

$$\leq \frac{\frac{1}{b^2} \sum_{\xi \in S^k} \sigma^2}{\frac{\sigma^2 \cdot b}{b^2}} = \frac{\sigma^2}{b}$$

Pytorch: HB Polyak \Rightarrow Stoch HB Polyak

$$g^k = \beta g^{k-1} + (1-\beta) \nabla J(x^k, \xi^k)$$

$$x^k \approx x^{k-1}$$

смысл системы стохастических
(горячий процесс HB)

для оценки дисперсии:

$$E[\|x^{k+1} - x^*\|_2^2] \leq \underbrace{\left(1 - \frac{\mu}{L}\right)^{k+1}}_{\text{убывание}} E[\|x^0 - x^*\|_2^2] + \underbrace{\frac{\sigma^2}{\mu^2 k}}_{\text{суммарная погр. из-за шума}}$$

для оценки дисперсии

$$E[\|x^{k+1} - x^*\|_2^2] \leq \left(1 - \frac{\mu}{L}\right)^{k+1} E[\|x^0 - x^*\|_2^2] + \frac{\sigma^2}{\mu^2 k}$$