

$$\text{Minima } t^* \in \mathbb{R} : \varphi(t^*) = 0$$

$$\varphi: \mathbb{R} \rightarrow \mathbb{R}$$

$$\triangle t^0 \xrightarrow{\text{guess}} \Delta t: t^0 + \Delta t \approx t^*$$

$$\varphi(t^0 + \Delta t) = \varphi(t^0) + \varphi'(t^0) \Delta t + o(\Delta t)$$

$$\varphi(t^*) = 0$$

$$\varphi(t^0 + \Delta t) \approx 0$$

$$\varphi(t^0) + \varphi'(t^0) \Delta t \approx 0$$

$$\Delta t = - \frac{\varphi(t^0)}{\varphi'(t^0)}$$

$$t^1 = t^0 + \Delta t$$

$$\boxed{t^{k+1} = t^k - \frac{\varphi(t^k)}{\varphi'(t^k)}}$$

nennt Newtons ganz neues Rezept

Beispiel:

$$\varphi(t) = \frac{t}{(1+t^2)^{1/2}}$$

$$t^* = 0$$

$$\varphi'(t) = \frac{1}{(1+t^2)^{3/2}}$$

$$t^{k+1} = t^k - \frac{\varphi(t^k)}{\varphi'(t^k)}$$

$$= t^k - \frac{t^k}{\frac{1}{(1+(t^k)^2)^{3/2}}}$$

$$= t^k (1 - (1 + (t^k)^2)) = -(t^k)^3$$

- $|t^0| < 1$ $\frac{1}{2} \rightarrow -\frac{1}{8} \rightarrow \frac{1}{8^2} \rightarrow -\frac{1}{(8^2)^2}$

Скорее сходимость к решению

- $|t^0| = 1$ $1 \rightarrow -1 \rightarrow 1 \rightarrow -1$
нет сходимости

- $|t^0| > 1$ расходимость

Метод Ньютона - только локальная сходимость

$$\min_{x \in \mathbb{R}^d} f(x)$$

в минимуме: $\nabla f(x^*) = 0$

Алгоритм 3 Метод Ньютона

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K-1$ **do**
- 2: Вычислить $\nabla f(x^k)$, $\nabla^2 f(x^k)$
- 3: $x^{k+1} = x^k - (\nabla^2 f(x^k))^{-1} \nabla f(x^k)$
- 4: **end for**

Выход: x^K

Минимизация:

$$f(x) \approx f(x^k) + \langle \nabla f(x^k); x - x^k \rangle + \frac{1}{2} \langle x - x^k; \nabla^2 f(x^k) (x - x^k) \rangle$$

$\rightarrow \min_x$ $\text{argmin} = x^{k+1}$ $\frac{1}{2} \|x - x^k\|_2^2$ - geo шаг

$$\nabla f(x^k) + \nabla^2 f(x^k) (x - x^k) = 0$$

\uparrow
 x^{k+1}

$$X^{(r+1)} = X^k - (\nabla^2 f(x^k))^{-1} \nabla f(x^k)$$

Док. б.е. выполняются:

- f - μ -convex function $\nabla^2 f(x) \succeq \mu I$
- $\|\nabla^2 f(x) - \nabla^2 f(y)\|_2 \leq M \|x - y\|_2$
↑
линейная норма

$$X^{(r+1)} - X^* = X^k - (\nabla^2 f(x^k))^{-1} \nabla f(x^k) - X^*$$

Применяя лемму:

$$\nabla f(x^k) - \nabla f(x^*) = \int_0^1 \nabla^2 f(x^* + \tau(x^k - x^*)) (x^k - x^*) d\tau$$

$$X^{(r+1)} - X^* = X^k - (\nabla^2 f(x^k))^{-1} \left[\int_0^1 \nabla^2 f(x^* + \tau(x^k - x^*)) (x^k - x^*) d\tau \right] X^*$$

$$= I \underline{I(x^k - x^*)} - (\nabla^2 f(x^k))^{-1} \left[\int_0^1 \nabla^2 f(x^* + \tau(x^k - x^*)) \underline{(x^k - x^*)} d\tau \right]$$

$$= (\nabla^2 f(x^k))^{-1} \nabla^2 f(x^k) (x^k - x^*) - (\nabla^2 f(x^k))^{-1} \left[\int_0^1 \nabla^2 f(x^* + \tau(x^k - x^*)) (x^k - x^*) d\tau \right]$$

$$x^{k+1} - x^* = -(\nabla^2 f(x^k))^{-1} \int_0^1 (\nabla^2 f(x^* + \tau(x^k - x^*)) - \nabla^2 f(x^k)) d\tau (x^k - x^*)$$

$$\| \quad \|_2$$

$$\|x^{k+1} - x^*\|_2 =$$

$$\left\| (\nabla^2 f(x^k))^{-1} \int_0^1 (\nabla^2 f(x^* + \tau(x^k - x^*)) - \nabla^2 f(x^k)) d\tau (x^k - x^*) \right\|_2$$

$$\|Ax\|_2 \leq \|A\|_2 \|x\|_2$$

$$\|x^{k+1} - x^*\|_2 \leq$$

$$\left\| (\nabla^2 f(x^k))^{-1} \int_0^1 (\nabla^2 f(x^* + \tau(x^k - x^*)) - \nabla^2 f(x^k)) d\tau \right\|_2 \cdot \|x^k - x^*\|_2$$

$$\|AB\|_2 \leq \|A\|_2 \cdot \|B\|_2$$

$$\leq \left\| \nabla^2 f(x^k)^{-1} \right\|_2 \cdot \left\| \int_0^1 (\nabla^2 f(x^* + \tau(x^k - x^*)) - \nabla^2 f(x^k)) d\tau \right\|_2 \cdot \|x^k - x^*\|_2$$

$$1) \left\| \int_0^1 (\nabla^2 f(x^* + \tau(x^k - x^*)) - \nabla^2 f(x^k)) d\tau \right\|_2$$

$$\leq \int_0^1 \|\nabla^2 f(x^* + \tau(x^k - x^*)) - \nabla^2 f(x^*)\|_2 d\tau$$

M-лм. гессиана

$$\leq \int_0^1 M \|x^* + \tau(x^k - x^*) - x^*\|_2 d\tau$$

$$= \int_0^1 M(1-\tau) \|x^k - x^*\|_2 d\tau = \frac{M}{2} \|x^k - x^*\|_2$$

$$2) \quad \|(\nabla^2 f(x^k))^{-1}\|_2$$

$\nabla^2 f(x^k) \succeq \mu I$ *сильно выпуклость*

$$(\nabla^2 f(x^k))^{-1} \preceq \frac{1}{\mu} I$$

$$\|(\nabla^2 f(x^k))^{-1}\|_2 \leq \frac{1}{\mu}$$

$$\|x^{k+1} - x^*\|_2 \leq \frac{1}{\mu} \cdot \frac{M}{2} \|x^k - x^*\|_2 \cdot \|x^k - x^*\|_2$$

Теорема об оценке сходимости метода Ньютона для μ -сильно выпуклых функций с M -Липшецевым гессианом

Пусть задача безусловной оптимизации с μ -сильно выпуклой целевой функцией f с M -Липшецевыми гессианом решается методом Ньютона. Тогда справедлива следующая оценка сходимости за 1 итерацию

$$\|x^{k+1} - x^*\|_2 \leq \frac{M}{2\mu} \|x^k - x^*\|_2^2$$

квадратическое сжатие

$$\bullet \quad M=2 \quad \mu=1 \quad \|x^0 - x^*\|_2 = \frac{1}{2} \\ \frac{1}{2} \rightarrow \left(\frac{1}{2}\right)^2 \rightarrow \left(\left(\frac{1}{2}\right)^2\right)^2 \rightarrow \left(\left(\left(\frac{1}{2}\right)^2\right)^2\right)^2$$

Богачев

нормальное сечение

$$\|x^1 - x^*\|_2 \leq \|x^0 - x^*\|_2$$

$$\frac{\mu}{2L} \|x^0 - x^*\|_2 < 1 \Rightarrow \|x^0 - x^*\|_2 \leq \frac{2L}{\mu}$$

Многочисленным методом для зад. функции

• Децентрализованный метод

$$x^{k+1} = x^k - \gamma_k (\nabla^2 f(x^k))^{-1} \nabla f(x^k)$$

$$\gamma = \arg \min_{\gamma} f(x^k + \gamma p_k)$$

$$p_k = -(\nabla^2 f(x^k))^{-1} \nabla f(x^k)$$

• $x^{k+1} = \arg \min_{x \in \mathbb{R}^d} \left\{ f(x^k) + \langle \nabla f(x^k), x - x^k \rangle + \frac{L}{2} \|x - x^k\|_2^2 \right\}$

$$x^{k+1} = x^k - \frac{1}{L} \nabla f(x^k)$$

$$x^{k+1} = \arg \min_{x \in \mathbb{R}^d} \left\{ f(x^k) + \langle \nabla f(x^k), x - x^k \rangle + \frac{1}{2} \langle x - x^k, \nabla^2 f(x^k) (x - x^k) \rangle + \frac{\mu}{6} \|x - x^k\|_2^3 \right\}$$

μ -норм. сечение

Кусочным методом

На что нужно смотреть?

$$x^{l+1} = x^k - H_k \nabla f(x^k)$$

\uparrow
 $(\nabla^2 f(x^k))^{-1}$ gew. Hessematrix

Näher: Näheresolung von H_k ab- bz. zu

$$\nabla f(x^k) \approx \nabla f(x^{k+1}) + \nabla^2 f(x^{k+1}) (x^k - x^{k+1})$$

$$\underbrace{\nabla f(x^k) - \nabla f(x^{k+1})}_{-g^k} \approx \nabla^2 f(x^{k+1}) \underbrace{(x^k - x^{k+1})}_{= s^k}$$

$$(\nabla^2 f(x^{k+1}))^{-1} g^k = s^k$$

quasi-Newton-
 Update

$$\boxed{\begin{array}{l} H_{k+1} y^k = s^k \\ H_{k+1}^+ = H_{k+1} \end{array}}$$

Sei y^k neue
 Richtung
 in xlamem
 Update

• SR1 / Broyden - optimierendes Verfahren

$$H_{k+1} = H_k + \underbrace{\mu_k}_{\in \mathbb{R}} \underbrace{q^k (q^k)^T}_{\in \mathbb{R}^d}$$

$$\begin{aligned} s^k &= H_{k+1} y^k = (H_k + \mu_k q^k (q^k)^T) y^k \\ &= H_k y^k + \underbrace{\mu_k}_{\in \mathbb{R}} \underbrace{q^k (q^k)^T y^k}_{\in \mathbb{R}} \end{aligned}$$

$$q^k \parallel s^k - H_k y^k$$

$$|q^k = s^k - H_k g^k|$$

$$q^k = \mu_k q^k (q^k)^T y^k$$

$$1 = \mu_k (q^k)^T y^k$$

$$\mu_k = \frac{1}{(q^k)^T y^k}$$

$O(d^2)$ операция на итерацию

($O(d^3)$ - кубичная)

• BFGS

$$H_{k+1} = \arg \min_{H \in \mathbb{R}^{d \times d}} \|H - H_k\|^2$$

$$\text{s.t. } s^k = H y^k$$

$$H^T = H$$

$$\|A\|_W = \|W^{1/2} A W^{1/2}\|_F$$

$$W y^k = s^k$$

$$H_{k+1} = (I - \rho_k s^k (y^k)^T) H_k (I - \rho_k y^k (s^k)^T) + \rho_k s^k (s^k)^T$$

$$\rho_k = \frac{1}{(y^k)^T s^k}$$

матрица ранга одно
 $O(d^2)$

Квази-монотонность метода след сужающемуся

Квазиньютоновские методы: BFGS

- До такой формулы можно дойти по-другому. Рассмотрим $B_{k+1} = H_{k+1}^{-1}$. Для B квазиньютоновское уравнение выглядит как

$$B_{k+1}s^k = y^k$$

- Для B_{k+1} можно написать SR1 пересчет матрицы:

$$B_{k+1} = B_k + \frac{(y^k - B_k s^k)(y^k - B_k s^k)^T}{(y^k - B_k s^k)^T s^k}$$

- Смотрим на вид B_{k+1} и делаем из нее двухранговое изменение:

$$B_{k+1} = B_k + \mu_{k,1} y^k (y^k)^T + \mu_{k,2} B_k y^k (B_k y^k)^T$$

- Как и в SR1 можно подогнать $\mu_{k,1}$ и $\mu_{k,2}$:

$$B_{k+1} = B_k + \frac{y^k (y^k)^T}{(y^k)^T s^k} + \frac{B_k s^k (B_k s^k)^T}{(s^k)^T B_k s^k}$$

- Если теперь обратить B_{k+1} (формула Шермана-Маррисона-Вудберри), то получится выражение для H_{k+1}