

Методы оптимизации. Семинар 2. Матрично-векторное дифференцирование.

Корнилов Никита Максимович

МФТИ ФИВТ

11 сентября 2025г

Дифференцируемость по Фреше

Работаем в множествах U, V линейных нормированных полных (банаховых) пространств.

Definition

Функция $f : U \rightarrow V$ дифференцируема по Фреше во внутренней точке $x \in \text{int} U$, если существует линейный оператор $df(x) : U \rightarrow V$, т.ч.

$$f(x + h) = f(x) + df(x)[h] + o(\|h\|), \|h\| \rightarrow 0.$$

$df(x)$ называется производной f в точке x .

Если точка x не является внутренней, то понятие дифференцируемости не определено.

Definition

Приращение дифференцируемой функции f в точке x с приращением h называется дифференциалом $df(x)[h] \in V$. Часто направление h обозначают как dx , а дифференциал как $df(x)[dx]$.

Производная по направлению

В одномерном случае $f : \mathbb{R} \rightarrow \mathbb{R}$, показателем скорости изменения f в точке x вдоль числовой прямой является производная:

$$f'(x) := \lim_{t \rightarrow 0} \frac{f(x+t) - f(x)}{t}.$$



В многомерном случае $f : U \rightarrow V$, направлений изменения не два, а бесконечно много. Производные по направлению отвечают за изменения функции вдоль одного направления $h \in U$:

Definition

Производной по направлению $h \in U$ функции $f : U \rightarrow V$ во внутренней точке $x \in \text{int} U$ называется

$$\frac{\partial f}{\partial h}(x) := \lim_{t \rightarrow +0} \frac{f(x+th) - f(x)}{t} = \frac{\partial f(x)[h]}{t \cdot \|h\|} \quad (1)$$

Если для любого $h \in U$ определена производная по направлению $\frac{\partial f}{\partial h}(x)$, то функция f дифференцируема по Гато в точке x .

Lemma

Если функция f дифференцируема по Фреше в x , то производная по направлению $\frac{\partial f}{\partial h}(x)$ существует, линейна по h и равна дифференциалу $df(x)[h]$.

В матанализе показывается, что из дифференцируемости по Фреше следует существование производных по всем направлениям. Однако обратное неверно. Достаточным условием будет непрерывность всех частных производных.

Градиент по вектору

- ✓ ✓
- В случае $f : \mathbb{R}^n \rightarrow \mathbb{R}$ дифференциал $df(x)[dx] \in \mathbb{R}$ можно представить в виде

$$df(x)[dx] = \langle \nabla f(x), dx \rangle, \quad \text{где вектор } \nabla f(x) \in \mathbb{R}^n \text{ зависит от } x.$$

Вектор $\nabla f(x)$ называется **градиентом** функции. Взяв $h = e_i = (0, \dots, 0, \underset{i}{1}, 0, \dots, 0) \in \mathbb{R}^n$, получим формулу градиента в стандартном базисе

$$\langle \nabla f(x), e_i \rangle = \sum_{j=1}^n \nabla f(x)_j e_{ij}$$

$$\nabla f(x) = \left(\frac{\partial f}{\partial x_1}(x), \dots, \frac{\partial f}{\partial x_n}(x) \right)^T \in \mathbb{R}^n, \quad (2)$$

где $\frac{\partial f}{\partial x_i}(x) := \lim_{t \rightarrow 0} \frac{f(x + te_i) - f(x)}{t}$ — частные производные по i -ой координате.

Градиент по матрице

- У ✓
- В случае $f : \mathbb{R}^{n \times m} \rightarrow \mathbb{R}$ дифференциал $df(X)[dX] \in \mathbb{R}$ можно представить в виде

$$df(X)[dX] = \langle \nabla f(X), dX \rangle,$$

где матрица $\nabla f(X) \in \mathbb{R}^{n \times m}$ зависит от X .

Матрица $\nabla f(X)$ также называется **градиентом** функции.

Аналогично взяв $h = e_{ij}$, получим формулу градиента в стандартном базисе

$$\nabla f(X) = \left(\frac{\partial f}{\partial x_{ij}}(X) \right)_{i,j} \in \mathbb{R}^{n \times m}.$$

(3)

$$e_{ij} = \begin{pmatrix} 0 & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & 1 & \dots & 0 \end{pmatrix}$$


Матрица Якоби

- В случае $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ дифференциал $df(x)[dx] \in \mathbb{R}^m$ можно представить в виде

$$df(x)[dx] = J_f(x)dx, \quad \text{где матрица } J_f(x) \in \mathbb{R}^{m \times n} \text{ зависит от } x.$$

Матрица $J_f(x)$ называется матрицей Якоби.

Аналогично взяв $h = e_j$, получим формулу матрицы Якоби в стандартном базисе


$$J_f(x) \equiv \frac{\partial f}{\partial x} := \left(\frac{\partial f_i}{\partial x_j}(x) \right)_{i,j} \in \mathbb{R}^{m \times n}. \quad (4)$$

Заметим, что $\nabla f(x) = J_x^\top$.


$$\mathbb{R}^n \rightarrow \mathbb{R}^{1 \times n} \quad Jf = \left(\frac{\partial f}{\partial x_1}, \dots, \frac{\partial f}{\partial x_n} \right)$$

Таблица канонических видов

$$\langle x, \Delta x \rangle, \quad \tau \in \mathbb{R} \quad \Rightarrow \quad \langle 0 \notin \mathbb{C}, \Delta x \rangle$$

Выход \ Вход	Скаляр	Вектор
Скаляр	$df(x) = f'(x)dx$ $f'(x)$ скаляр, dx скаляр.	-
Вектор	$df(x) = \langle \nabla f(x), dx \rangle$ $f(x)$ вектор, dx вектор	$df(x) = J_x dx$ J_x матрица, dx вектор
Матрица	$df(X) = \langle \nabla f(X), dX \rangle$ $\nabla f(X)$ мат, dX мат	-

Стоит отметить, что данная таблица верна и для произвольных скалярных произведений, а не только для стандартного.

Подходы к вычислению производных

$$f(x) = f(x_1, \dots, x_n)$$

1 Прямой подход

Идея: выразить функцию $f(x)$ через скалярную зависимость от каждой координаты x_i и напрямую искать частную производную $\frac{\partial f(x)}{\partial x_i}$.

2 Дифференциальный подход

Идея: Используя правила вычисления дифференциалов, получить канонический вид из Таблицы (8) и выделить градиенты функций, гессиан или матрицу Якоби.

Дифференциальное исчисление: правила

ϕ $+$ T $\phi = \text{коор}$	Правила преобразования		
	$d(\alpha X) = \alpha dX$		$\lambda \in \mathbb{R}$
	$d(AXB) = AdXB$		$A, B = \text{const}$
	$d(X + Y) = dX + dY$ $d(X^T) = (dX)^T$		
ϕ	$d(XY) = (dX)Y + X(dY)$		$\rightarrow XY$
	$d\langle X, Y \rangle = \langle dX, Y \rangle + \langle X, dY \rangle$		$\langle X, Y \rangle$
ϕ	$d\left(\frac{X}{\phi}\right) = \frac{\phi dX - (d\phi)X}{\phi^2}$		$\phi: V \rightarrow \mathbb{R}$
	$d(g(f(x))) = dg(f)[df(x)]$		- скалярное
\cdot	$J_{g(f)} = J_g J_f \iff \frac{\partial g}{\partial x} = \frac{\partial g}{\partial f} \frac{\partial f}{\partial x}$		
	$df(x, y) = J_x dx + J_y dy$		

Стоит отметить, что данная таблица верна и для произвольных скалярных произведений и гильбертовых ЛНП.

Дифференциальное исчисление: табличные производные

Таблица стандартных производных	
$dA = 0$	$d(ax^2) = 2ax \, dx$
$d\langle A, X \rangle = \langle A, dX \rangle$	
$d\langle Ax, x \rangle = \langle (A + A^T)x, dx \rangle$	$A \in \mathbb{R}^{n \times n}$
$d \operatorname{Tr}(X) = \operatorname{Tr}(dX)$	
$d(\det(X)) = \det(X) \operatorname{Tr}(X^{-1} dX)$	
$d(X^{-1}) = -X^{-1}(dX)X^{-1}$	

Стоит отметить, что данная таблица верна и для произвольных скалярных произведений и гильбертовых ЛНП.

Hint. Для запоминания формулы $d(X^{-1})$

$$I = XX^{-1},$$

$$dI = 0 = d(XX^{-1}) = (dX)X^{-1} + Xd(X^{-1}),$$

$$d(X^{-1}) = -X^{-1}(dX)X^{-1}.$$

Однако это не является доказательством существования дифференциала.

Example

Найдите первый дифференциал и градиент функции $\nabla f(x)$ для

$$f(x) = \frac{1}{2} \langle Ax, x \rangle + \langle b, x \rangle + c,$$

где $A \in \mathbb{R}^{n \times n}$, $b \in \mathbb{R}^n$, $c \in \mathbb{R}$.

$$f(x) = \frac{1}{2} \langle Ax, x \rangle + \langle b, x \rangle + c$$

$$\delta f(x) = \delta \left(\frac{1}{2} \langle Ax, x \rangle \right) + \delta \langle b, x \rangle + \delta c$$

\Downarrow \Downarrow \Downarrow
 $\frac{1}{2} \langle Ax, x \rangle$ $\langle b, x \rangle = 0$ 0
 \Downarrow \Downarrow
 $\frac{1}{2} \langle (A + A^T)x, x \rangle$ $\langle b, x \rangle$

$$\frac{1}{2} \langle (A + A^T)x, x \rangle \quad (\text{---})$$

$$\delta \langle Ax, x \rangle \Rightarrow \langle A(x + \delta x), x + \delta x \rangle - \langle Ax, x \rangle =$$

$$\langle Ax, x \rangle + \langle A \delta x, x \rangle + \langle Ax, \delta x \rangle + \langle A \delta x, \delta x \rangle - \langle Ax, x \rangle =$$

$$\langle A \delta x, x \rangle + \langle Ax, \delta x \rangle + \langle A \delta x, \delta x \rangle$$

$$\Downarrow$$

$$\langle \delta x, A^T x \rangle$$

$$\langle (A^T + A)x, \delta x \rangle + \langle A \delta x, \delta x \rangle$$

$\approx 0(\|\delta x\|)$

$$|\langle A \delta x, \delta x \rangle| \leq \|A\| \|\delta x\| \|\delta x\| \leq \|A\| \|\delta x\|^2$$

$\|\delta x\| \rightarrow 0$

$$g(x + \delta x) = f(x) + \langle A + A^T x, \delta x \rangle + o(\|\delta x\|)$$

$$\delta \left(\underbrace{Ax}_{\mathbb{R}^{n \times 1}} \right) = A \delta x$$

$$df(x) = \underbrace{\langle (A+A^T)x, dx \rangle}_2 + \langle b, dx \rangle$$

$$= \underbrace{\langle (A+A^T)x + b, dx \rangle}_2 = \langle \nabla f(x), dx \rangle$$

$$\nabla f(x) = \underbrace{(A+A^T)x + b}_2$$

$$\nabla f(x) = \left(\frac{\partial f}{\partial x_i} \right)_{i=1}^n$$

$$f(\dots, x_i, \dots) = \underbrace{\langle Ax, x \rangle}_2 + \langle b, x \rangle + c$$

$$= \sum_{k=1}^n \sum_{j=1}^n \underbrace{a_{kj} x_k x_j}_2 + \sum_{k=1}^n b_k x_k + c$$

$$\frac{\partial}{\partial x_i}$$

Вторая производная

Пусть $f : U \rightarrow V$ дифференцируема в каждой точке $x \in U$.

Рассмотрим дифференциал функции $df(x)[h_1]$ при фиксированном приращении $h_1 \in U$ как функцию от x :

$$g(x) = df(x)[h_1].$$

Definition (Вторая производная)

Если в некоторой точке $x \in U$ функция $g : U \rightarrow V$ дифференцируема, то второй дифференциал $d^2f(x)[h_1, h_2] : U \times U \rightarrow V$ имеет вид

$$d^2f(x)[h_1, h_2] := d(df[h_1])(x)[h_2]. \quad (5)$$

Можно показать, что $d^2f(x)[h_1, h_2]$ билинейная функция по h_1, h_2 . По аналогии определяется третий дифференциал $d^3f(x)[h_1, h_2, h_3]$, четвёртый и так далее.

В случае $f : \mathbb{R}^n \rightarrow \mathbb{R}$ второй дифференциал, как и любую билинейную функцию, можно представить с помощью матрицы

$$d^2 f(x)[dx_1, dx_2] = \langle \nabla^2 f(x) dx_1, dx_2 \rangle.$$

Матрица $\nabla^2 f(x)$ называется **гессианом** функции. В стандартном базисе гессиан имеет вид

$$\nabla^2 f(x) = \left(\frac{\partial^2 f}{\partial x_i \partial x_j}(x) \right)_{ij} \in \mathbb{R}^{n \times n}.$$

Напомним, что для дважды непрерывно дифференцируемой функции гессиан - симметричная матрица. В общем случае, удобно считать гессиан как

$$\nabla^2 f(x) = (J_{\nabla f})^\top. \quad d(\nabla f) : \mathbb{R}^n \rightarrow \mathbb{R}^n$$

$J_{\nabla f}$

Квадратичная функция

$$J^2 f = \left(\frac{\partial \nabla f_i}{\partial x_j} \right) = \left(\frac{\partial^2 f}{\partial x_j \partial x_i} \right)$$

Вывод из теор. о непрерывности смешанных производных $\rightarrow (J^2 f) = \nabla^2 f(x)$

Example

Найдите второй дифференциал и гессиан функции $\nabla^2 f(x)$ для

$$f(x) = \frac{1}{2} \langle Ax, x \rangle + \langle b, x \rangle + c,$$

где $A \in \mathbb{R}^{n \times n}$, $b \in \mathbb{R}^n$, $c \in \mathbb{R}$.

$$df(x|E dx_1) = \left\langle \frac{(A+A^T)x+b}{2}, dx_1 \right\rangle$$

$$d\left(df(x|E dx_1)\right) = d\left\langle \frac{(A+A^T)x+b}{2}, dx_1 \right\rangle$$

$$= \left\langle d\left(\frac{(A+A^T)x+b}{2}\right), dx_1 \right\rangle$$

$$= \left\langle \frac{(A+A^T)dx_2 + 0}{2}, dx_1 \right\rangle$$

$$= \left\langle \frac{(A+A^T)}{2} dx_2, dx_1 \right\rangle$$

$$= \left\langle \nabla^2 f(x) dx_1, dx_2 \right\rangle$$

$$= \left\langle dx_2, \left(\frac{(A+A^T)}{2}\right)^T dx_1 \right\rangle$$

$$\left(\frac{(A+A^T)}{2}\right)^T = \frac{A^T + A}{2}$$

$$\nabla f(x) = \frac{(A+A^T)x+b}{2}$$

$$d\nabla f(x) = \frac{(A+A^T)}{2} dx = J_0 f dx$$

$$\nabla^2 f(x) = (J_0 f)^T$$

Example

Найдите первый и второй дифференциалы, а также градиент $\nabla f(x)$ и гессиан $\nabla^2 f(x)$ функции

$$f(x) = \ln \langle Ax, x \rangle$$

где $x \in \mathbb{R}^n$, $A \in S_{++}^n$.

$$f(x) = \ln \langle Ax, x \rangle \quad A \in S_{++}^n$$

$$df(x) = d(\ln \langle Ax, x \rangle) \stackrel{(*)}{=} y = \langle Ax, x \rangle$$

$$\stackrel{(**)}{=} d(\ln y) = \frac{1}{y} dy = \frac{d\langle Ax, x \rangle}{\langle Ax, x \rangle}$$

$$= \frac{\langle (A + A^T)x, dx \rangle}{\langle Ax, x \rangle} = \left\langle \frac{2Ax}{\langle Ax, x \rangle}, dx \right\rangle$$

$$= \langle df(x), dx \rangle \Rightarrow df(x) = \frac{2Ax}{\langle Ax, x \rangle}$$

$$d|df(x)| = d\left(\frac{2Ax}{\langle Ax, x \rangle}\right) = (d(2Ax) \langle Ax, x \rangle - 2Ax d\langle Ax, x \rangle) / \langle Ax, x \rangle^2$$

$$= \frac{2A dx \langle Ax, x \rangle - 2Ax \cdot \langle 2Ax, dx \rangle}{\langle Ax, x \rangle^2}$$

$$= \frac{2A dx \langle Ax, x \rangle - 2Ax \cdot \langle 2Ax, dx \rangle}{\langle Ax, x \rangle^2} = \text{Jof } dx$$

$$\forall Ax \langle Ax, dx \rangle = \forall Ax (Ax)^T dx =$$

$$\forall Ax x^T A^T dx$$

$$= \left(\frac{2A}{\langle Ax, x \rangle} - \frac{4Ax x^T A}{\langle Ax, x \rangle^2} \right) \delta x$$

$$\nabla \phi = 0 \ell^2(x)$$

$$\nabla \ell^2(x) = \nabla \phi =$$

$$(Ax x^T A)^T = Ax x^T A$$

Example

Найдите первый и второй дифференциалы, а также градиент $\nabla f(x)$ и гессиан $\nabla^2 f(x)$ функции

$$f(x) = \frac{1}{3} \|x\|_2^3, \quad x \in \mathbb{R}^n \setminus \{0\}.$$

Example

Найдите первый и второй дифференциалы, а также градиент $\nabla f(x)$ и гессиан $\nabla^2 f(x)$ функции

$$f(x) = \ln(1 + \exp(\langle a, x \rangle)),$$

где $a \in \mathbb{R}^n$.

Example

Найдите матрицу Якоби функции $s(x) = \text{softmax}(x)$

$$\text{softmax}(x) := \left(\frac{\exp(x_1)}{\sum_{i=1}^n \exp(x_i)}, \dots, \frac{\exp(x_n)}{\sum_{i=1}^n \exp(x_i)} \right)^T.$$

Example

Найти градиент $\nabla f(X)$ и дифференциал функции $f(X)$

$$f(X) = \|AX - B\|_F, \quad X \in \mathbb{R}^{k \times n},$$

где $A \in \mathbb{R}^{m \times k}, B \in \mathbb{R}^{m \times n}$.

$$f(x) = \|AX - B\|_F =$$

$$\sqrt{\langle AX - B, AX - B \rangle}$$

$$\delta \sqrt{\langle AX - B, AX - B \rangle} \stackrel{(\ominus)}{=} \delta \sqrt{z} \stackrel{(\ominus)}{=}$$

$$z = \langle AX - B, AX - B \rangle$$

$$\|AX - B\|_F^2$$

$$\frac{1}{2\sqrt{z}} \delta z =$$

$$\frac{\delta \langle AX - B, AX - B \rangle}{2 \|AX - B\|_F} \stackrel{(\ominus)}{=}$$

$$Y = AX - B \stackrel{(\ominus)}{=} \frac{\delta \langle Y, Y \rangle}{2 \|AX - B\|_F} \stackrel{(\ominus)}{=}$$

$$\langle Y, \delta Y \rangle + \langle \delta Y, Y \rangle = 2 \langle Y, \delta Y \rangle =$$

$$\stackrel{(\ominus)}{=} \frac{2 \langle Y, \delta Y \rangle}{2 \|AX - B\|_F} = \frac{\langle AX - B, \delta(AX - B) \rangle}{\|AX - B\|_F}$$

$$= \frac{\langle AX - B, A \delta X \rangle}{\|AX - B\|_F} = \langle \phi(x), \delta x \rangle \stackrel{(\ominus)}{=}$$

$$\langle A, B \rangle = \text{Tr}(A^T B)$$

$$\Leftrightarrow \frac{\text{Tr} \left(\overbrace{(AX-B)^T \cdot A} \right) \cdot dX}{\|AX-B\|_F} =$$

$$= \frac{\langle \underbrace{(AX-B)^T A}_{\|AX-B\|_F}, dX \rangle =$$

$$= \left\langle \underbrace{n A^T (A^T A - B^T)}_{\|AX-B\|_F}, dX \right\rangle$$

$$\nabla f(X) \in \mathbb{R}^{n \times n}$$

Example

Найдите первый дифференциал и градиент $\nabla f(X)$ функции $f(X)$

$$f(X) = \det(AX^{-1}B),$$

где A, X, B – такие матрицы с нужными размерностями, что $AX^{-1}B$ обратима.

$$\det(A X^{-1} B) =$$

$$\det(A X^{-1} B) \operatorname{Tr} \left((A X^{-1} B)^{-1} \det(A X^{-1} B) \right)$$

$$\Rightarrow \underbrace{(A X^{-1} B)^{-1}}_{\substack{\text{matrix} \\ \text{inverse}}} \neq B^{-1} X A^{-1}$$

$$\det(A X^{-1} B) = A \det X^{-1} B =$$

$$= A X^{-1} \det X X^{-1} B$$

$$\Rightarrow \det(A X^{-1} B) =$$

$$\operatorname{Tr} \left((A X^{-1} B)^{-1} A X^{-1} \det X X^{-1} B \right)$$

$$= \langle \operatorname{vec}(X), \det X \rangle = \operatorname{Tr}(\operatorname{vec}^T X)$$

$$\text{Tr} \left(\begin{pmatrix} A_1 & & \\ & \ddots & \\ & & A_n \end{pmatrix} \right) = \text{Tr}(A_n A_{n-1} \dots A_1)$$

A_i - invertible

$$\text{Tr} \left((AX^{-1}B)^{-1} AX^{-1} J X X^{-1} B \right)$$

$$= \det(AX^{-1}B)$$

$$= \text{Tr} \left(X^{-1} B (AX^{-1}B)^{-1} AX^{-1} J X \right)$$

$$\nabla F(x) = -\det(AX^{-1}B)$$

$$(X^{-1})^T A^T (AX^{-1}B)^{-1} B^T X^{-1} \quad \textcircled{=}$$

$$(X^{-1})^T = (X^T)^{-1} \quad X^{-1}$$

$$\textcircled{=} X^{-T} A^T (AX^{-1}B)^{-T} B^T X^{-T}$$

Example

Найдите первый и второй дифференциалы, а также градиент $\nabla f(X)$ функции $f(X)$

$$f(X) = \ln(\det(X))$$

заданной на множестве $X \in \mathbb{S}_{++}^n$ в пространстве \mathbb{S}^n .

Example

Найти градиент $\nabla f(X)$ и дифференциал функции $f(X)$

$$f(X) = \text{Tr}(AX^{\top}X).$$